LAPORAN PRAKTIKUM PERAMALAN VAR



Disusun Untuk Memenuhi Tugas

Mata Kuliah:

Praktikum Pemodelan Statistika Terapan

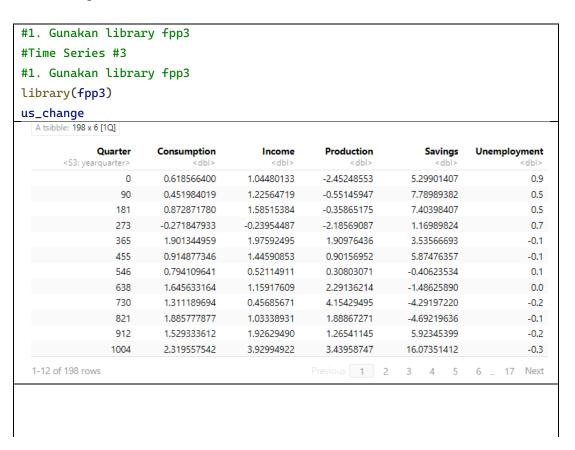
Wahyu Ikbal Maulana

(3323600056)

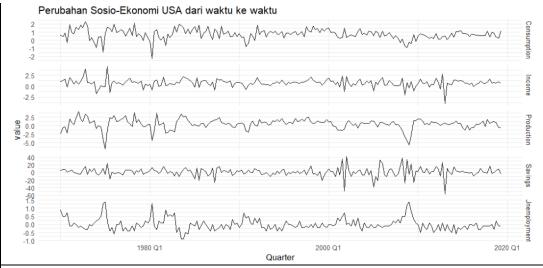
PROGRAM STUDI STr SAINS DATA TERAPAN
POLITEKNIK ELEKTRONIKA NEGERI SURABAYA

A. Percobaan 3

a. Kode, Output, dan Analisis



```
#2. EDA
us_change %>%
  pivot_longer(-Quarter, names_to = "variable", values_to = "value") %>%
  ggplot(aes(x = Quarter, y = value)) +
  geom_line() +
  facet_grid(variable ~ ., scales = "free_y") +
  labs(title = "Perubahan Sosio-Ekonomi USA dari waktu ke waktu") +
  theme_minimal()
```



Di atas adalah EDA untuk membuat plot untuk setiap variabel untuk mengetahui secara garis besar data sudah stasioner atau belum

```
library(tseries)

df <- us_change[, -1]

stationary_test <- data.frame("ADF" = double(), "KPSS" = double())

for (i in 1:ncol(df)) {
    stationary_test[i, "ADF"] <- adf.test(pull(df[, i]))$p.value
    stationary_test[i, "KPSS"] <- kpss.test(pull(df[, i]))$p.value
}

stationary_test %>%
    mutate(variable = colnames(df)) %>%
    select(variable, ADF, KPSS)
```

Description: df [5 × 3]

	variable <chr></chr>	ADF <dbl></dbl>	KPSS <dbl></dbl>
1	Consumption	0.01	0.1
2	Income	0.01	0.1
3	Production	0.01	0.1
4	Savings	0.01	0.1
5	Unemployment	0.01	0.1

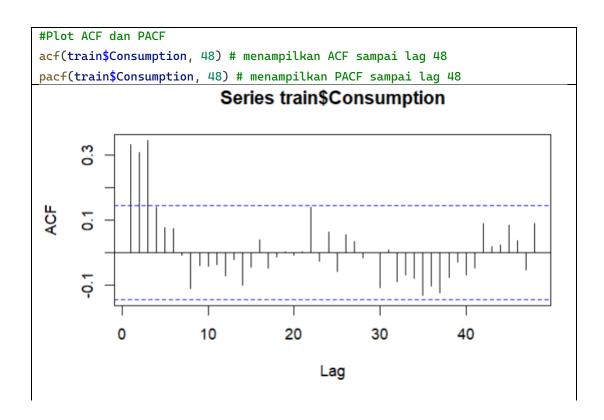
5 rows

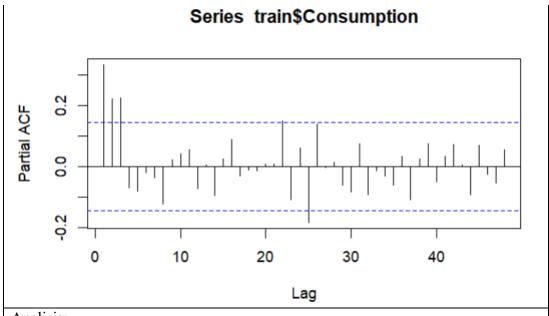
Berdasarkan p-value pada ADF test, seluruh variabel mempunyai p-value 0.01 (Stasioner) dan KPSS test 0.1 (Stasioner), sehingga didapat bahwa kelima variabel tersebut signifikan stasioner.

```
test <- us_change %>%
  mutate(year = year(Quarter)) %>%
  filter(year >= 2016)
train <- us_change %>%
  mutate(year = year(Quarter)) %>%
  filter(year < 2016)</pre>
```

Analisis:

Membagi dataset menjadi 2 subset data, yakni data train dan data test.





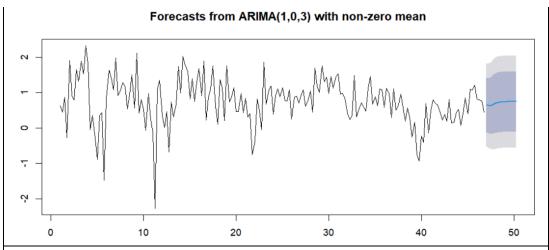
Menampilkan plot ACF dan plot PACF sampai dengan lag 48

```
library(forecast)
fit <- auto.arima(ts(train$Consumption, frequency = 4), seasonal = F)</pre>
summary(fit)
Series: ts(train$Consumption, frequency = 4)
 ARIMA(1,0,3) with non-zero mean
 Coefficients:
ar1 ma1 ma2 ma3 mean
0.5747 -0.3581 0.093 0.1946 0.7418
s.e. 0.1526 0.1635 0.081 0.0857 0.0936
 sigma^2 = 0.3533: log likelihood = -163.03
AIC=338.06 AICc=338.53 BIC=357.35
Training set error measures:
                                 RMSE
                                                        MPE
                       ME
                                             MAE
Training set 0.001107612 0.5862617 0.4378066 -35.61455 161.7278
                   MASE
                                 ACF1
Training set 0.672272 -0.002685885
```

Analisis:

Menampilkan "summary" dari pemodelan ARIMA orde "(1,0,3)" dan menampilkan ukuran error pada model data train ARIMA.

```
#Prediksi/forcasting
fore <- forecast(object = fit, h = nrow(test))
plot(fore)</pre>
```



Di atas adalah hasil plot untuk visualisasi peramalan dari model ARIMA

```
#Model ARIMAX
library(forecast)
library(lmtest)
datay = train[,2]
datax = train[,3:6]
estimasiarmax = arima(datay, order=c(1,0,3), xreg=datax)
estimasiarmax; coeftest(estimasiarmax)
Call:
arima(x = datay, order = c(1, 0, 3), xreg = datax)
Coefficients:
                        ma2
                                 ma3 intercept Income
                                                        Production
        ar1
                 ma1
      0.0508 -0.1519 0.1674 -0.1657
                                         0.2461 0.7628
                                                            0.0422
      0.2762
             0.2685 0.0878 0.1048
                                         0.0352
                                                0.0429
                                                            0.0236
      Savings Unemployment
      -0.0541
                   -0.1648
       0.0033
                    0.0995
sigma^2 estimated as 0.09544: log likelihood = -45.02, aic = 108.03
z test of coefficients:
              Estimate Std. Error z value Pr(>|z|)
ar1
             0.0507915 0.2761992
                                  0.1839
                                           0.85410
ma1
            -0.1518913 0.2684846 -0.5657
                                           0.57157
ma2
             0.1673974
                       0.0877953
                                   1.9067
ma3
             -0.1656920 0.1047923
                                  -1.5811
                                           0.11384
             0.2460633
                       0.0352217
                                  6.9861 2.826e-12 ***
intercept
                                  17.7837 < 2.2e-16 ***
Income
             0.7627902
                       0.0428927
Production
            0.0422120
                       0.0235944
                                  1.7891 0.07360
Savings
            -0.0541032
                        0.0032678 -16.5564 < 2.2e-16 ***
Unemployment -0.1647536 0.0994910 -1.6560
                                          0.09773 .
Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '. ' 0.1 ' ' 1
```

Analisis:

Ringkasan model ARIMA menunjukkan orde ARIMA yang telah disesuaikan, sementara pengujian koefisien menggunakan fungsi coeftest() menghasilkan uji statistik untuk masing-masing koefisien dalam model, yang memungkinkan untuk menentukan signifikansi mereka dalam memprediksi variabel respons.

Dengan menggunakan model ARIMA dengan variabel eksogen, Anda dapat memperhitungkan efek variabel prediktor dalam memprediksi variabel respons. Ini dapat meningkatkan akurasi ramalan Anda dengan memasukkan informasi tambahan yang relevan ke dalam model.

```
#Model ARIMAX
library(forecast)
library(lmtest)
datay = train[,2]
#datax = cbind(train[,3],train[,5:6])
datax = train[,3:6]
estimasiarmax2 = arima(datay, order=c(0,1,1), xreg=datax)
estimasiarmax2; coeftest(estimasiarmax2)
Call:
arima(x = datay, order = c(0, 1, 1), xreg = datax)
Coefficients:
       mal Income Production Savings Unemployment
-0.9771 0.7288 0.0384 -0.0519 -0.2258
                                                  -0.2258
                          0.0384 -0.0519
0.0252 0.0030
s.e. 0.0165 0.0415
                                                       0.1063
sigma^2 estimated as 0.1003: log likelihood = -50.82, aic = 111.64
z test of coefficients:
                Estimate Std. Error z value Pr(>|z|)
ma1
              -0.9770868 0.0164651 -59.3430 < 2e-16 ***
Income 0.7288264 0.0414953 17.5641 < 2e-16 ***

Production 0.0384058 0.0252318 1.5221 0.12798

Savings -0.0518911 0.0030238 -17.1609 < 2e-16 ***
Unemployment -0.2258255 0.1063100 -2.1242 0.03365 *
Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' 1
```

Analisis:

Dengan menggunakan model ARIMAX, Anda dapat memperhitungkan efek variabel prediktor eksternal dalam memprediksi variabel respons. Ini memungkinkan Anda untuk memperbaiki akurasi ramalan Anda dengan memasukkan informasi tambahan yang relevan ke dalam model.

Nilai estimasi koefisien dari model ARIMAX. Anda memiliki koefisien untuk komponen moving average (ma1) serta untuk masing-masing variabel eksogen (Income, Production, Savings, dan Unemployment). Koefisien positif atau negatif menunjukkan arah dan kekuatan hubungan antara variabel eksogen dan variabel respons.

```
summary(estimasiarmax)
arima(x = datay, order = c(1, 0, 3), xreg = datax)
Coefficients:
                 ma1
                         ma2
                                  ma3 intercept Income Production
        ar1
0.0508 -0.1519 0.1674 -0.1657 0.2461 0.7628
s.e. 0.2762 0.2685 0.0878 0.1048 0.0352 0.0429
                                                               0.0422
                                                               0.0236
     Savings Unemployment
      -0.0541 -0.1648
s.e.
     0.0033
                    0.0995
sigma^2 estimated as 0.09544: log likelihood = -45.02, aic = 108.03
Training set error measures:
                           RMSE
                    ME
                                       MAE
                                                 MPE
                                                           MAPE
Training set 0.02702775 0.322829 0.2434111 0.07587493 0.7515478
                  MASE
                              ACF1
Training set 0.5419737 -0.05040848
```

Menampilkan ringkasan dari "estimasiarmax" dengan menampilkan ukuran error pada model train.

```
res_arimax=estimasiarmax2$residuals

Box.test(res_arimax,lag = 20)

Box-Pierce test

data: res_arimax

X-squared = 24.699, df = 20, p-value = 0.2132
```

Analisis:

Uji Box-Pierce yang dijalankan bertujuan untuk menguji apakah ada ketergantungan serial pada residual dari model ARIMAX. Dengan nilai p-value sebesar 0.2132 (lebih besar dari tingkat signifikansi umum 0.05), gagal menolak hipotesis nol. Ini menunjukkan bahwa tidak ada bukti yang cukup untuk menyatakan bahwa ada ketergantungan serial dalam residual pemodelan ARIMAX. Dengan demikian, model mungkin berhasil menangkap pola-pola dalam data dengan baik.

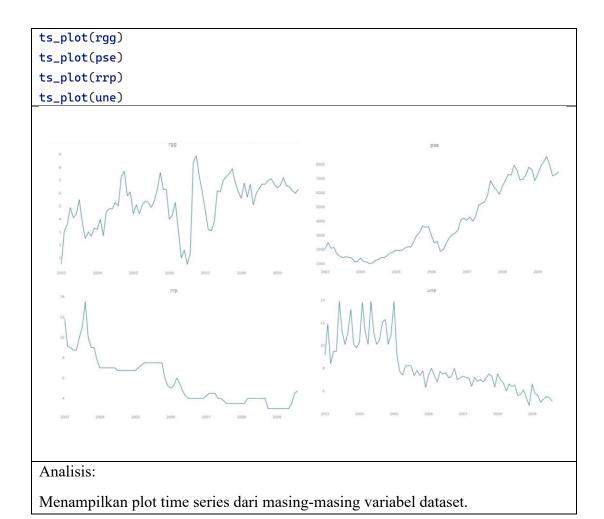
B. Percobaan 4

a. Kode, Output, dan Analisis

```
library(vars)
library(mFilter)
library(tseries)
library(TSstudio)
library(forecast)
library(tidyverse)
```

late :chr>	real_gdp_growth <dbl></dbl>	psei <dbl></dbl>	bsp_rrp <dbl></dbl>	unem <dbl></dbl>
/31/1999	0.5	2028.21	11.875	9.1
/30/1999	3.1	2486.96	9.125	11.9
/30/1999	3.6	2096.20	9.000	8.4
2/31/1999	4.9	2142.97	8.750	9.5
/31/2000	4.1	1681.72	8.750	9.5
/30/2000	4.4	1533.99	10.000	13.9
rows				

```
rgg <- ts(mp$real_gdp_growth, start = c(2003,1,1), frequency = 12)
pse <- ts(mp$psei, start = c(2003,1,1), frequency = 12)
rrp <- ts(mp$bsp_rrp, start = c(2003,1,1), frequency = 12)
une <- ts(mp$unem, start = c(2003,1,1), frequency = 12)</pre>
```



```
#Uji Stasioneritas

pp.test(rgg)

pp.test(pse)

pp.test(rrp)

pp.test(une)
```

```
Warning: p-value smaller than printed p-value
        Phillips-Perron Unit Root Test
data: rgg
Dickey-Fuller Z(alpha) = -34.082, Truncation lag parameter =
3, p-value = 0.01
alternative hypothesis: stationary
        Phillips-Perron Unit Root Test
data: pse
Dickey-Fuller Z(alpha) = -9.2626, Truncation lag parameter =
3, p-value = 0.5715
alternative hypothesis: stationary
        Phillips-Perron Unit Root Test
data: rrp
Dickey-Fuller Z(alpha) = -22.911, Truncation lag parameter =
3, p-value = 0.02667
alternative hypothesis: stationary
Warning: p-value smaller than printed p-value
       Phillips-Perron Unit Root Test
data: une
Dickey-Fuller Z(alpha) = -51.958, Truncation lag parameter =
3, p-value = 0.01
alternative hypothesis: stationary
```

Menguji stasioneritas data, dapat disimpulkan bahwa semua data dari setiap variabel bersifat stasioner.

```
#Estimasi menggunakan VAR tanpa PSE
v1 <- cbind(rgg, rrp, une)
colnames(v1) <- cbind("RGG","RRP","UNE")
v2 <- cbind(rgg, pse, rrp)
colnames(v2) <- cbind("RGG","PSE","RRP")
lagselect <- VARselect(v1, lag.max = 15, type = "const")
lagselect
lagselect$selection</pre>
```

```
$selection
AIC(n) HQ(n) SC(n) FPE(n)
     1.5
                                    2
AIC(n) -1.3346640 -1.3908480 -1.6355168 -1.6504343 -1.4206943
HQ(n) -1.1762760 -1.1136690 -1.2395467 -1.1356732 -0.7871421
SC(n) -0.9332387 -0.6883537 -0.6319534 -0.3458019 0.1850071
FPE(n) 0.2633696 0.2494910 0.1962965 0.1951398 0.2491424
                              7
                                            8
                                                            9
                    6
                                                                               10
AIC(n) -1.4418180 -1.5687384 -1.4773771 -1.4577291 -1.3984550
HQ(n) -0.6894748 -0.6976042 -0.4874519 -0.3490128 -0.1709478 
SC(n) 0.4649524 0.6391010 1.0315313 1.3522483 1.7125914 
FPE(n) 0.2492901 0.2264155 0.2586502 0.2787891 0.3178962
                 11 12 13 14
AIC(n) -1.30221158 -1.2050768 -1.2467267 -1.6504750 -1.89072155
HQ(n) 0.04408668 0.2600124 0.3371536 0.0521963 -0.06925919 
SC(n) 2.10990382 2.5081076 2.7675267 2.6648474 2.72566988 
FPE(n) 0.38393762 0.4760861 0.5305820 0.4289395 0.43101959
AIC(n) HQ(n) SC(n) FPE(n)
          3 1
   15
```

Melakukan estimasi VAR tanpa menggunakan variabel "PSE". Dapat diketahui, bahwa kriteria yang digunakan untuk memilih jumlah lag terbaik adalah AIC (Akaike Information Criterion). Jumlah lag terbaik yang dipilih berdasarkan AIC adalah 15. Namun, mungkin penting untuk melihat juga hasil kriteria informasi lainnya untuk memastikan konsistensi dalam pemilihan jumlah lag terbaik.

```
#Model Diagnostik
Model1 <- VAR(v1, p = 2, type = "const", season = NULL, exog = NULL)
Model2 <- VAR(v2, p = 2, type = "const", season = NULL, exog = NULL)
summary(Model1)
  VAR Estimation Results:
 Endogenous variables: RGG, RRP, UNE
Deterministic variables: const
Sample size: 78
Log Likelihood: -319.319
Roots of the characteristic polynomial:
0.355 0.5928 0.4971 0.4971 0.2507 0.99807
  Call: VAR(y = v1, p = 2, type = "const", exogen = NULL)
                                                                                                   Estimation results for equation UNE:
  Estimation results for equation RGG:
  RGG = RGG.11 + RRP.11 + UNE.11 + RGG.12 + RRP.12 + UNE.12 + const UNE = RGG.11 + RRP.11 + UNE.11 + RGG.12 + RRP.12 + UNE.12 + const
                                                                        Estimate Std. Error t value Pr(>|t|)
RGG.11 8.79677 0.11464 6.958 1.45e-89 ***
RRP.11 -0.3869 0.2176 -0.115 0.885146
UNE.11 0.81273 0.16383 0.123 0.992794
RGG.12 -0.20417 0.11682 -1.842 0.865660
RRP.12 -0.11575 0.20676 -0.577 0.566650
UNE.12 -0.81229 0.16555 -0.173 0.863387
const 3.06626 0.87349 3.510 0.000782 ***
                                                                                                                  Estimate Std. Error t value Pr(>|t|)
                                                                                                                                                         4.134 9.63e-05 ***
                                                                                                                                                                          0.861
                                                                                                                                                                       0.139
  Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
                                                                                                    Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
  Residual standard error: 1.181 on 71 degrees of freedom
Multiple R-Squared: 0.5814, Adjusted R-squared: 0.546
F-statistic: 16.43 on 6 and 71 DF, p-value: 9.028e-12
                                                                                                    Residual standard error: 1.324 on 71 degrees of freedom
Multiple R-Squared: 0.6968, Adjusted R-squared: 0.6'
F-statistic: 27.2 on 6 and 71 DF, p-value: < 2.2e-16
                                                                                                                                                             Adjusted R-squared: 0.6712
  Estimation results for equation RRP:
  RRP = RGG.l1 + RRP.l1 + UNE.l1 + RGG.l2 + RRP.l2 + UNE.l2 + const
 Estimate Std. Error t value Pr(*|t|)
RG II 0.06435 0.06079 1.059 0.2934
RRP.11 0.96465 0.1227 8.592 1.33e-12 ***
UNE.11 0.09761 0.05596 1.773 0.0806
RGG.12 -0.05779 0.05597 0.033 0.3288
RRP.12 -0.10184 0.10646 -0.957 0.3420
UNE.12 0.01425 0.05613 0.224 0.8003
const -0.22843 0.46322 -0.493 0.6234
                                                                                   Covariance matrix of residuals:

RGG RRP UNE

RGG 1.39523 0.02849 0.04877

RRP 0.02849 0.39237 -0.01243

UNE 0.04877 -0.01243 1.75300
  Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '. 0.1 ' 1 Correlation matrix of residuals:
                                                                                                    RGG 1.00000 0.03851 0.03118
RRP 0.03851 1.00000 -0.01498
  Residual standard error: 0.6264 on 71 degrees of freedom
Multiple R-Squared: 0.9272, Adjusted R-squared: 0.921
F-statistic: 150.6 on 6 and 71 DF, p-value: < 2.2e-16
                                                                                                    UNE 0.03118 -0.01498 1.00000
```

Menampilkan ringkasan statistik dari variabel model1.

```
Arch1 <- arch.test(Model1, lags.multi = 15, multivariate.only = TRUE)

Arch1

ARCH (multivariate)

data: Residuals of VAR object Model1
Chi-squared = 378, df = 540, p-value = 1
```

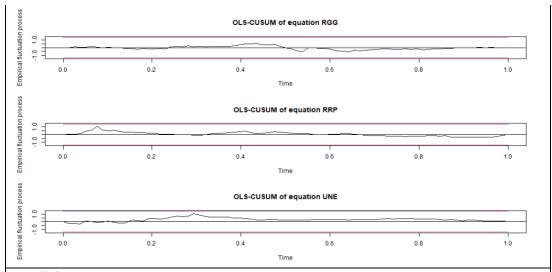
Analisis:

Hasil uji statistik ARCH (Autoregressive Conditional Heteroskedasticity) menunjukkan hasil uji keberadaan heteroskedastisitas kondisional dalam residu model VAR. berdasarkan hasil uji ini, tidak ada bukti yang cukup untuk menolak hipotesis nol bahwa tidak ada heteroskedastisitas kondisional dalam residu model VAR Anda. Ini mengindikasikan bahwa residu tersebut mungkin homoskedastis dan tidak menunjukkan pola heteroskedastisitas kondisional yang signifikan.

Analisis

Berdasarkan hasil ini, dapat disimpulkan bahwa residu dari model VAR tidak mengikuti distribusi normal multivariat. Hal ini ditunjukkan oleh nilai p-value yang sangat kecil untuk JB-Test, skewness multivariat, dan kurtosis multivariat.

```
Stability1 <- stability(Model1, type = "OLS-CUSUM")
plot(Stability1)</pre>
```

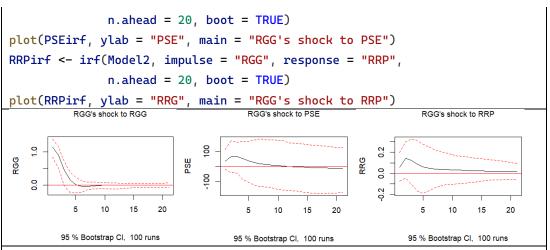


Menampilkan visualisasi untuk menguji stabilitas koefisien model VAR terhadap perkembangan struktural menggunakan metode OLS-CUSUM.

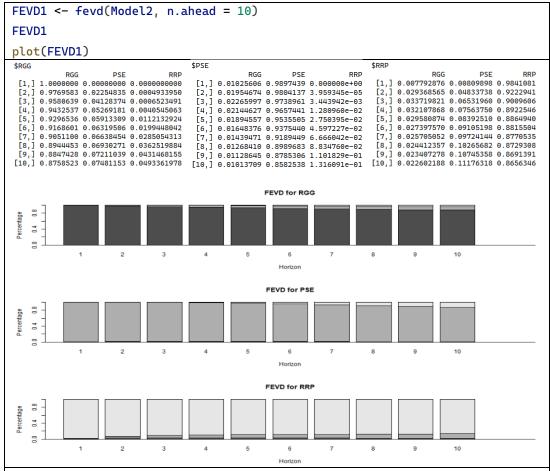
```
Granger_rgg<- causality(Model2, cause = "RGG")</pre>
Granger_rgg
Granger_pse <- causality(Model2, cause = "PSE")</pre>
Granger_pse
Granger_rrp <- causality(Model2, cause = "RRP")</pre>
Granger_rrp
$Granger
                                                                    $Instant
        Granger causality H0: RGG do not Granger-cause PSE RRP
                                                                            HO: No instantaneous causality between: PSE and RGG RRP
data: VAR object Model2
F-Test = 0.69645, df1 = 4, df2 = 213, p-value = 0.5952
                                                                    data: VAR object Model2
Chi-squared = 1.4044, df = 2, p-value = 0.4955
                                                                    $Granger
        HO: No instantaneous causality between: RGG and PSE RRP
                                                                            Granger causality HO: RRP do not Granger-cause RGG PSE
data: VAR object Model2
Chi-squared = 1.5007, df = 2, p-value = 0.4722
                                                                    data: VAR object Model2
F-Test = 1.2118, df1 = 4, df2 = 213, p-value = 0.3068
$Granger
                                                                    $Instant
        Granger causality H0: PSE do not Granger-cause RGG RRP
                                                                            HO: No instantaneous causality between: RRP and RGG PSE
data: VAR object Model2
F-Test = 1.9295, df1 = 4, df2 = 213, p-value = 0.1067
                                                                    data: VAR object Model2
Chi-squared = 1.2202, df = 2, p-value = 0.5433
```

Analisis:

Hasil output memberikan insight dari tentang hubungan kausalitas antarvariabel dalam model VAR.



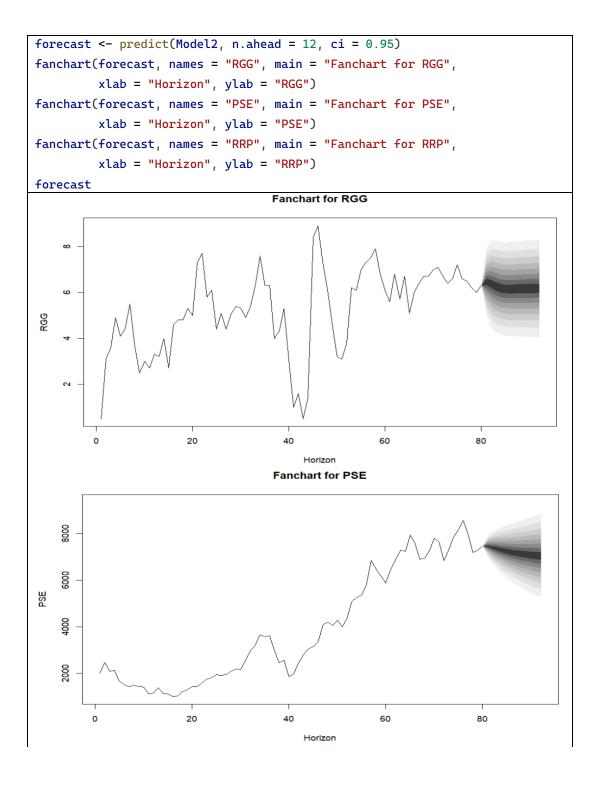
Membuat visualisasi dengan menampilkan plot dari setiap respons impuls yang dihasilkan.

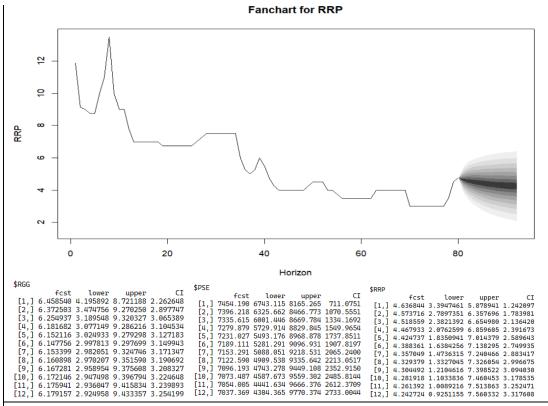


Analisis:

Menghitung dekomposisi varians kesalahan ramalan (FEVD) dari model VAR Anda yang disimpan dalam variabel Model2. Setelah menjalankan fungsi fevd(),

menampilkan tabel dekomposisi varians kesalahan ramalan untuk setiap variabel dalam model VAR. Kemudian, membuat visualisasi plot dari hasil FEVD.





Membuat ramalan dalam 12 bulan ke depan menggunakan model VAR lalu kemudian forecasting ini kemudian digunakan untuk membuat grafik untuk setiap variabel. Setiap grafik memiliki sumbu X yang menunjukkan jangka waktu masa depan sedangkan sumbu Y yang menunjukkan nilai ramalan untuk variabel yang sesuai.